

强化学习指南1：环境配置和第一节课

一、实验目的

1. 理解强化学习的核心概念：智能体（Agent）、环境（Environment）、状态（State）、动作（Action）与奖励（Reward）。
2. 掌握马尔可夫决策过程（MDP）的基础数学表达。
3. 理解并实现 Q-Learning 算法的核心状态动作价值更新。
4. 完成强化学习标准环境库 `Gymnasium` 的配置，并运行首个 Demo。

二、实验环境搭建（基于 conda）

在进行强化学习实验前，为了避免依赖冲突，我们统一使用 Miniconda/Anaconda 进行虚拟环境隔离。

[【Windows】Miniconda3下载安装保姆级教程-CSDN博客](#)

这是对应指导conda下载。

（如果下载好了就继续按照接下来的）

2.1 创建与激活虚拟环境

打开终端（Terminal）或 Anaconda Prompt，执行以下命令创建一个名为 `rl_course` 的 Python 3.10 环境：

```
# 1. 创建虚拟环境
conda create -n rl_course python=3.10 -y
# 2. 激活虚拟环境
conda activate rl_course
```

2.2 安装核心依赖库

在本课程中，我们将使用目前强化学习学术界与工业界的标准环境库 `gymnasium`（替代已停止维护的 `gym`），以及用于矩阵运算的 `numpy` 和用于绘制训练曲线的 `matplotlib`。

```
# 3. 安装依赖（推荐在激活的 conda 环境下使用 pip 安装 gymnasium）
pip install gymnasium numpy matplotlib
```

安装 pytorch 的教程（这个库后续会用到）

[PyTorch 安装 | 菜鸟教程](#)

三、任务说明：

实验题目

基于随机滑动 FrozenLake 的 Q-learning 求解实验

实验目的

1. 理解 Gymnasium 中 FrozenLake 环境的状态、动作、奖励与终止机制。
2. 掌握表格型 Q-learning 的基本实现方法。
3. 观察在随机滑动条件下，探索机制对学习效果的影响。
4. 比较在 `8x8 预设地图` 与 `自定义 12x12 地图` 上，Q-learning 的训练难度与最终表现差异。

FrozenLake-v1 是 Gymnasium Toy Text 中的经典离散环境，支持预设 `4x4`、`8x8` 地图，也支持通过 `desc` 传入自定义地图；当 `is_slippery=True` 时，动作具有随机性，不一定严格朝期望方向移动。

使用 Gymnasium 预设地图：

```
env = gym.make("FrozenLake-v1", map_name="8 x 8", is_slippery=True)
```

实验要求：

1. 实现 Q-learning

需要自行实现以下部分：

- Q 表初始化
- `epsilon-greedy` 动作选择
- Q-learning 更新公式
- 训练过程

- 测试过程

核心更新公式为：

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

FrozenLake 的 Gymnasium 官方教程就是使用表格型 Q-learning 来求解该环境。也可以进行查阅。

2. 必须启用随机滑动

两种环境都必须设置：

```
is_slippery=True
```

官方文档说明，在 `is_slippery=True` 时，智能体会以一定概率滑向非预期方向；例如朝某个方向行动时，不一定真的按该方向前进。文档给出的说明是：在滑动模式下，智能体会以 1/3 的概率朝期望方向移动，并以 1/3 的概率朝两个垂直方向之一移动

3. 比较两种地图上的学习效果

至少比较以下指标：

- 平均回报
- 成功率
- 平均步数
- 训练曲线变化趋势

4. 输出最终策略

训练结束后，需要输出每个状态的贪婪策略，例如使用箭头表示：

- 0：左
- 1：下
- 2：右
- 3：上

FrozenLake 的动作空间是离散 4 动作。

5. 可视化结果

至少完成以下一种可视化：

- 训练奖励曲线
- 成功率曲线
- 最终策略网格图
- 动态效果图

建议参数范围

这些是你可以在实验要求里给出的建议值，不是唯一答案：

- 学习率 `alpha`: 0.05 ~ 0.2
- 折扣因子 `gamma`: 0.95 ~ 0.99
- 初始探索率 `epsilon`: 1.0
- 最小探索率 `epsilon_min`: 0.01 ~ 0.05
- 探索衰减 `epsilon_decay`: 0.995 ~ 0.9995
- 训练回合数：
 - 8×8：至少 5000 回合
 - 12×12：至少 10000 回合

由于 `is_slippery=True` 且地图规模较大，本实验训练难度明显高于 4×4 的基础版本，因此训练轮数应适当增加。